

Повышение качества инженерных чертежей

Целью проекта является повышение качества инженерных чертежей посредством разработки модели восстановления, превосходящей классические методы обработки изображений.

Для достижения поставленной цели были сформулированы следующие **задачи**:

1. Подготовка датасета FloorPlanCAD;
2. Реализация и обучение модели ConvAE для восстановления изображений низкого качества;
3. Анализ результатов обучения и проведение серии диагностических экспериментов для улучшения архитектуры и параметров обучения;
4. Разработка и обучение финальной модели восстановления инженерных чертежей;
5. Сравнительный анализ результатов предложенного метода и классических подходов обработки изображений.

Датасет FloorPlanCAD

В качестве исходных данных использовался датасет **FloorPlanCAD**. FloorPlanCAD - это крупномасштабный датасет с аннотированными CAD-чертежами планов этажей, предназначенный для задач обнаружения архитектурных объектов, анализа планировки и понимания пространства. Он используется в области машинного обучения, компьютерного зрения и архитектурного проектирования.




Рисунок 1 - Изображение из датасета FloorPlanCAD

Несмотря на архитектурную природу данных, изображения обладают рядом характеристик, близких к инженерным чертежам: преобладание тонких линий, высокая контрастность, наличие геометрических структур и значительная доля однородного фона.

Для решения задачи восстановления изображений был сформирован собственный paired dataset, состоящий из пар изображений высокого (**HQ, High Quality**) и низкого (**LQ, Low Quality**) качества.

Создание датасета осуществлялось в среде **ClearML** на основе исходных HQ-изображений. Для каждого HQ-изображения искусственно генерировалась деградированная версия (**LQ**) путём применения контролируемых искажений.



Рисунок 2 - Изображение плохого качества из измененного датасета FloorPlanCAD

Формирование LQ-изображений выполнялось в два этапа:

1. **Снижение разрешения изображения** (downscale–upscale): изображение случайным образом уменьшалось с коэффициентом **1/2 – 1/4**, после чего масштабировалось обратно до исходного размера.
2. **JPEG-сжатие**: применялось случайное JPEG-сжатие с уровнем качества в диапазоне **10–50**, моделирующее деградацию изображений при пересохранении и передаче.

Дополнительный шум в датасет **не добавлялся**, поскольку целью являлось моделирование реалистичных искажений, характерных для цифровых изображений схем и планировок.

После подготовки датасет содержал:

- **Всего paired images:** 2543
- **Train subset:** 2035 изображений
- **Validation subset:** 508 изображений

Первая предварительная диагностика датасета

Была проведена предварительная диагностика датасета, которая показала, что исходные LQ-изображения уже обладают сравнительно высокими значениями качества:

- PSNR mean: 25.73 dB
- SSIM mean: 0.8975
- Line L1 mean: 0.11463




Рисунок 3 - График метрик LQ изображений

Анализ был ориентирован исключительно на эти три метрики (**PSNR**, **SSIM**, **Line L1**), поскольку в последующих трех неудачных моделях использовались именно они.

Первые попытки обучения моделей

На раннем этапе проекта были протестированы несколько архитектур восстановления изображений, ориентированных преимущественно на повышение значения **PSNR (Peak Signal-to-Noise Ratio)** как основной метрики качества. Первоначальная гипотеза заключалась в том, что увеличение PSNR приведёт к улучшению визуального качества восстановленных изображений.

Convolutional AutoEncoder (ConvAE)

Структура модели

В качестве первой модели использовалась **ConvAE (Convolutional AutoEncoder)** с U-Net-подобной encoder-decoder архитектурой и skip-connections. Архитектура включала:

- **Encoder:** последовательность сверточных блоков (**64 → 128 → 256 каналов**) с уменьшением пространственного разрешения через **MaxPooling**.
- **Bottleneck:** слой из **512 каналов** с использованием **Dropout** для снижения переобучения.
- **Decoder:** последовательность слоёв **ConvTranspose2D** для восстановления разрешения изображения.
- **Skip-connections:** объединение признаков encoder и decoder для сохранения пространственной информации и деталей изображения.
- **Output layer:** сверточный слой с **Sigmoid-активацией** для получения итогового восстановленного изображения.

Функция потерь

Для обучения использовалась комбинированная функция потерь:

- **Weighted L1 Loss** - взвешенная попиксельная ошибка, где больший вес получают тёмные пиксели, соответствующие линиям и структурным элементам чертежа;
- **SSIM Loss** - оценка структурного сходства изображений;

Итоговая функция потерь имела вид:

$$\text{Loss} = \text{Weighted L1} + 0.5 \times \text{SSIM Loss}$$

Метрики качества

Для оценки качества восстановления использовались следующие метрики:

- **PSNR (Peak Signal-to-Noise Ratio)** - основная целевая метрика ранних экспериментов;
- **SSIM (Structural Similarity Index)** - степень структурного сходства изображений;
- **Weighted L1** - ошибка восстановления с повышенным штрафом за ошибки на линиях.



Рисунок 4 - Изменение значения PSNR в процессе обучения модели



Рисунок 5 - Динамика метрики SSIM в процессе обучения модели




Рисунок 6 - Изменение значения функции потерь L1 в процессе обучения модели

Эксперимент показал, что модель, продемонстрировала ограниченный прирост качества. Визуально восстановленные изображения сохраняли существенные недостатки:

- размытость тонких линий;
- потерю геометрических элементов и структурных деталей;
- ухудшение читаемости структурных деталей.

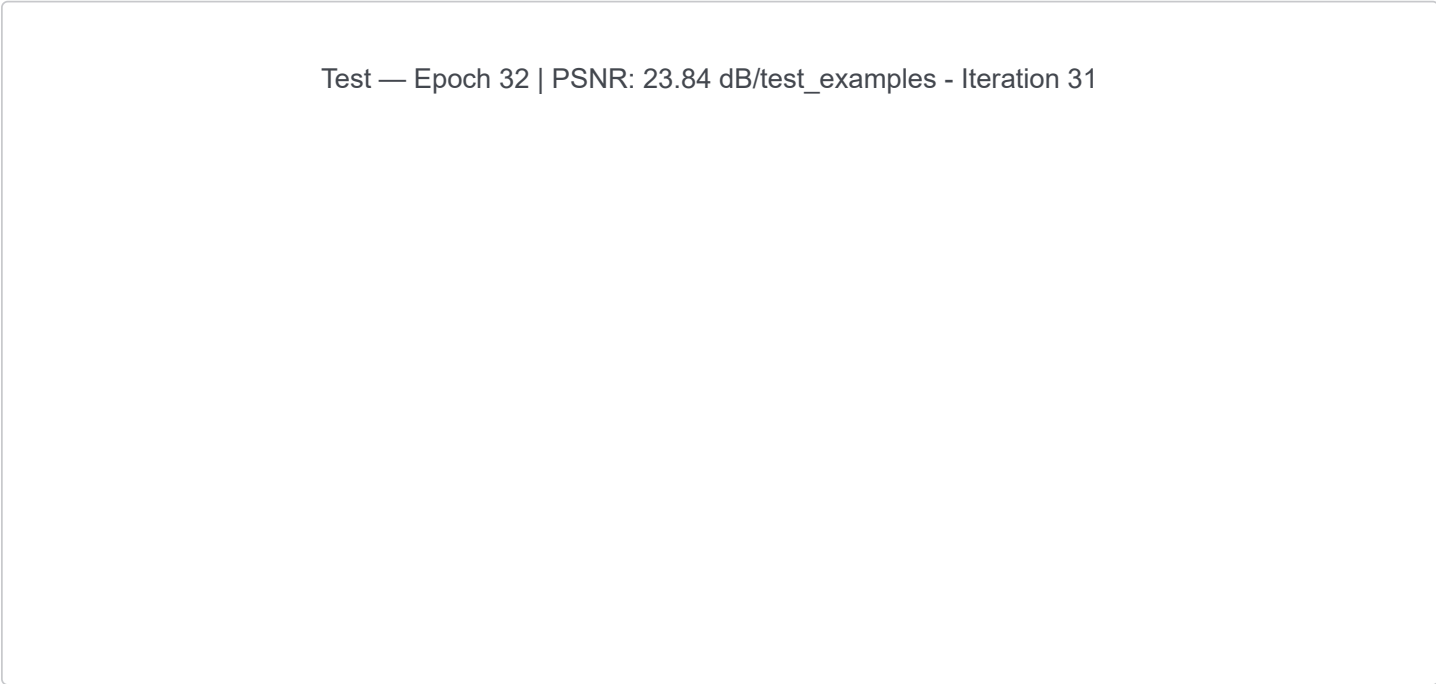


Рисунок 7 - Результат восстановления изображения датасета моделью

Residual ConvAE с MSE-оптимизацией

Структура модели

В качестве следующей модели использовалась **Residual ConvAE (Residual Convolutional AutoEncoder)** - encoder-decoder архитектура, обучающаяся предсказывать корректирующее преобразование относительно исходного изображения.

Архитектура включала:

- **Encoder:** последовательность сверточных блоков (**32 → 64 → 128 каналов**) с уменьшением пространственного разрешения посредством **MaxPooling**;
- **Bottleneck:** дополнительный сверточный блок для формирования компактного представления изображения;
- **Decoder:** последовательность операций **Upsampling + Convolution** для восстановления разрешения изображения;
- **Residual learning:** модель предсказывала не итоговое изображение, а **correction**, которая добавлялась к исходному **LQ-изображению** с небольшим коэффициентом масштабирования (**residual scale = 0.02**).

Функция потерь

Для обучения использовалась стандартная функция потерь:

- **MSE Loss (Mean Squared Error)** - среднеквадратичная ошибка между восстановленным и эталонным изображением.

Оптимизация по-прежнему была ориентирована преимущественно на улучшение **PSNR**.

Метрики качества

Для оценки качества восстановления использовались:

- **PSNR** - основная метрика качества и критерий выбора лучшей модели;
- **SSIM** - оценка структурного сходства изображений;
- **MSE** - среднеквадратичная ошибка восстановления.




Рисунок 8 - Изменение значения PSNR в процессе обучения модели




Рисунок 9 - Динамика метрики SSIM в процессе обучения модели




Рисунок 10 - Изменение значения функции потерь MSE в процессе обучения модели

Несмотря на более стабильное обучение по сравнению с первой версией, итоговое визуальное качество восстановления оставалось недостаточным. Получаемые изображения во многих случаях практически не демонстрировали заметного улучшения относительно исходных LQ-изображений: тонкие линии восстанавливались неточно, сохранялась размытость контуров, а мелкие структурные элементы по-прежнему терялись.

Epoch 96 | Model 23.883 | LQ 23.345 | Sharp 23.478 | Gain +0.538/continued_test_examples - It...

Рисунок 11 - Результат восстановления изображения датасета моделью

Residual U-Net

Структура модели

В качестве следующей модели использовалась **Residual U-Net** - encoder-decoder архитектура с **skip-connections** и residual learning, предназначенная для более качественного восстановления пространственных деталей изображения.

Архитектура включала:

- **Encoder:** последовательность сверточных блоков (**32 → 64 → 128 → 256 каналов**) с уменьшением пространственного разрешения посредством **MaxPooling**;
- **Bottleneck:** дополнительный сверточный блок для формирования компактного представления изображения;
- **Decoder:** последовательность операций **Upsampling + Convolution** с использованием **skip-connections** между encoder и decoder;
- **Residual learning:** модель предсказывала корректирующее преобразование (**correction**), которое добавлялось к исходному **LQ-изображению** с небольшим коэффициентом масштабирования (**residual scale = 0.02**).

Дополнительно использовалась стратегия выбора информативных патчей (**content-aware patch sampling**), при которой предпочтение отдавалось участкам изображения, содержащим линии и структурные элементы чертежей.

Функция потерь

Для обучения использовалась стандартная функция потерь:

- **MSE Loss (Mean Squared Error)** — среднеквадратичная ошибка между восстановленным и эталонным изображением.

Оптимизация модели по-прежнему была ориентирована преимущественно на повышение **PSNR**.

Метрики качества

Для оценки качества восстановления использовались:

- **PSNR** - основная целевая метрика и критерий выбора лучшей модели;
- **SSIM** - оценка структурного сходства изображений;
- **MSE** - среднеквадратичная ошибка восстановления.




Рисунок 12 - Изменение значения PSNR в процессе обучения модели



Рисунок 13 - Динамика метрики SSIM в процессе обучения модели




Рисунок 14 - Изменение значения функции потерь MSE в процессе обучения модели

Тем не менее, несмотря на улучшение количественных метрик и положительный прирост относительно baseline, итоговое визуальное качество восстановления всё ещё оставалось ограниченным. Получаемые изображения во многих случаях сохраняли недостаточную чёткость тонких линий и мелких геометрических элементов, а общий визуальный результат не обеспечивал существенного повышения читаемости инженерных чертежей.



Рисунок 15 - Результат восстановления изображения датасета моделью

Общий вывод по ранним моделям

Постепенное усложнение архитектуры действительно приводило к улучшению количественных метрик (PSNR, SSIM) и более стабильному процессу обучения. Однако даже при росте метрик итоговое визуальное качество восстановления оставалось недостаточным: сохранялась размытость линий, потеря мелких элементов и ограниченная читаемость структурных деталей. Полученные результаты показали, что оптимизация преимущественно по PSNR/MSE недостаточно эффективно отражает качество восстановления инженерных чертежей, что стало основанием для перехода к line-aware подходу.

Диагностика baseline и сравнение с классическими методами

Диагностика baseline показала, что исходные **LQ-изображения уже обладают сравнительно высоким уровнем качества**, что усложняет задачу восстановления и ограничивает возможный прирост метрик:

Метрика	Train	Validation
Base L1	0.024668	0.024767
Charbonnier	0.025058	0.025161
Weighted L1	0.252277	0.253771
Line L1	0.057686	0.056568
Edge Reference	0.134894	0.136243

Дополнительно было проведено сравнение с набором классических методов улучшения изображений (**OpenCV baselines**), включая sharpen, bilateral filtering, unsharp masking, thresholding и морфологические преобразования.

Наиболее эффективными оказались методы, основанные на **повышении резкости изображения**:

Метод	Line L1	Gain over LQ
sharpen_1.0	0.054809	+0.002684
bilateral_sharpen	0.055507	+0.001986
sharpen_0.5	0.055758	+0.001735
sharpen_0.25	0.056512	+0.000981
identity_lq (baseline)	0.057493	+0.000000

При этом часть классических методов демонстрировала ухудшение качества относительно baseline. Наиболее слабые результаты показали морфологические преобразования (**dark_close, dark_open**), приводившие к существенной деградации структурных элементов изображения.

В итоге получаем, что даже лучшие классические методы обеспечивают лишь ограниченное улучшение качества (**gain_line ≈ +0.002–0.003**), что подтвердило необходимость применения специализированной нейросетевой модели, ориентированной на восстановление тонких линий и геометрических структур инженерных чертежей.

Финальная модель

В качестве основы использовалась архитектура **Residual U-Net**, дополненная механизмом residual learning и специализированной функцией потерь, ориентированной на восстановление тонких линий и структурных элементов изображений.

В отличие от ранних экспериментов, ориентированных преимущественно на **PSNR/MSE**, в финальной модели основной акцент был смещён на качество восстановления геометрических структур. Для этого использовалась специализированная **line-aware функция потерь**, усиливающая вклад ошибок в областях линий и контуров. Дополнительно применялось residual supervision, при котором модель обучалась предсказывать корректирующее преобразование относительно исходного **LQ-изображения**. Основными метриками качества являлись **Line L1** и **gain_line**, отражающие качество восстановления структурных элементов относительно исходных изображений.

Структура модели

В качестве финальной модели использовалась **CleanResidualUNet** - модифицированная **Residual U-Net** архитектура, ориентированная на восстановление тонких линий и структурных элементов инженерных чертежей.

Архитектура включала:

- **Encoder:** последовательность сверточных блоков (**64 → 128 → 256 → 512 каналов**) с уменьшением пространственного разрешения посредством **MaxPooling**;
- **Bottleneck:** дополнительные residual-блоки для формирования более устойчивого и информативного представления изображения;

- **Decoder:** последовательность операций **Upsampling + Convolution** с использованием **skip-connections** между encoder и decoder;
- **Residual learning:** модель предсказывала корректирующее преобразование (**correction**) относительно входного изображения, а итоговый результат формировался как сумма исходного **LQ-изображения** и предсказанной residual-поправки.

Дополнительно применялась стратегия **content-aware patch sampling**, при которой обучение выполнялось преимущественно на участках изображения, содержащих линии и структурные элементы.

Функция потерь

$$\begin{aligned} \text{Loss} = & 0.20 \cdot \text{Base Loss} \\ & + 0.55 \cdot \text{Line-aware Loss} \\ & + 0.50 \cdot \text{Residual Loss} \\ & + 0.00 \cdot \text{Edge Loss} \end{aligned}$$

где:

- **Base Loss** - базовая ошибка восстановления изображения на основе **Charbonnier Loss**;
- **Line-aware Loss** - компонент с повышенным весом ошибок в областях линий и контуров изображения;
- **Residual Loss** - ошибка предсказания residual-поправки относительно разности **HQ – LQ**;
- **Edge Loss** - компонент восстановления границ изображения (в финальной конфигурации не использовался, вес равен **0**).

Для усиления внимания модели к структурным элементам использовалась **line mask**, увеличивающая штраф за ошибки в областях линий в **10 раз** относительно фоновых областей изображения.

Метрики качества

Для оценки качества восстановления использовались:

- **Line L1** - основная целевая метрика качества восстановления линий;
- **Gain Line** - прирост качества относительно исходных **LQ-изображений**;
- **Weighted L1** - ошибка восстановления с повышенным штрафом за ошибки на структурных элементах;
- **Edge Reference (edge_ref)** - качество восстановления контуров и границ объектов.

В отличие от ранних моделей, оптимизация в финальной версии была ориентирована преимущественно на качество восстановления структурных элементов изображения, а не на максимизацию **PSNR**.




Рисунок 16 - Динамика метрики Line L1 в процессе обучения финальной модели восстановления инженерных чертежей




Рисунок 17 - Прирост качества восстановления линий относительно исходных LQ-изображений (*gain_line*)



Рисунок 18 - Изменение значения функции потерь в процессе обучения финальной модели



Рисунок 19 - Изменение ошибки восстановления контуров (edge_ref) в процессе обучения

Для оценки эффективности обучения была выполнена сравнительная оценка ключевых метрик на начальном и лучшем этапе обучения модели.

Эпоха	Line L1 ↓	Gain Line ↑	Edge Ref ↓	Loss ↓
1	0.040512	+0.016981	0.087001	0.194610
65 (лучшая)	0.024008	+0.033485	0.049086	0.117540

В процессе обучения наблюдалось устойчивое снижение ошибки восстановления линий (**Line L1**) и общей функции потерь (**Loss**), а также постепенное увеличение прироста качества относительно baseline (**Gain Line**). Значение **Line L1** уменьшилось приблизительно с **0.041 до 0.024**, что свидетельствует о существенном улучшении качества восстановления геометрических структур и тонких линий инженерных чертежей. Одновременно наблюдался стабильный рост **gain_line**, подтверждающий способность модели не воспроизводить исходное **LQ-изображение**, а выполнять его осмысленное улучшение.

Дополнительно отмечалось снижение значения **edge_ref**, что указывает на улучшение качества восстановления контуров и границ объектов. Полученные результаты показали, что переход от оптимизации по **PSNR/MSE** к специализированному **line-aware подходу** позволил значительно повысить качество восстановления инженерных чертежей, обеспечив более эффективное восстановление структурных элементов и превосходство над классическими методами обработки изображений.



Рисунок 20 - Результат восстановления изображения датасета моделью

Сравнение финальной модели с baseline

Финальная модель существенно превосходит классические методы обработки изображений, демонстрируя прирост gain_line $\approx +0.033$, что более чем в 10 раз выше, чем у лучшего OpenCV baseline.

Метод	Line L1	Gain Line
Identity LQ	0.057493	+0.000000
sharpen_1.0	0.054809	+0.002684
bilateral_sharpen	0.055507	+0.001986
Final model	0.024008	+0.033485

Выводы

В рамках проекта была исследована задача **повышения качества инженерных чертежей**, представленных в виде низкокачественных изображений. Для решения поставленной задачи был подготовлен специализированный paired dataset на основе **FloorPlanCAD**, адаптированный под задачу восстановления изображений посредством моделирования реалистичных деградаций качества.

На ранних этапах проекта были протестированы несколько архитектур, ориентированных преимущественно на оптимизацию **PSNR/MSE**, включая различные варианты **ConvAE** и **Residual U-Net**. Проведённые эксперименты показали, что улучшение традиционных метрик качества изображения не гарантирует качественного восстановления инженерных чертежей. Несмотря на рост количественных показателей, итоговое визуальное качество оставалось недостаточным: сохранялась размытость тонких линий, терялись мелкие геометрические элементы, а восстановленные изображения во многих случаях слабо отличались от исходных **LQ-изображений**.

Дополнительная диагностика baseline и сравнение с классическими методами обработки изображений показали, что традиционные подходы повышения резкости и фильтрации обеспечивают лишь ограниченное улучшение качества и не позволяют эффективно восстанавливать структурные элементы чертежей.

В результате была разработана финальная **Residual U-Net модель с line-aware функцией потерь**, ориентированной на восстановление линий и геометрических структур изображения. Использование специализированных метрик качества (**Line L1**, **Gain Line**) и line-aware оптимизации позволило добиться устойчивого улучшения качества восстановления относительно baseline и превзойти классические методы обработки изображений.

Ключевым результатом работы стало установление того, что для задач восстановления инженерных чертежей **оптимизация исключительно по PSNR/MSE является недостаточной**, тогда как использование подходов, ориентированных на структурные элементы изображения, позволяет существенно повысить качество восстановления и читаемость инженерных схем.